SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Inteligentný systém pre automatizované hodnotenie bezpečnosti a governance AI systémov

Tímový projekt (TP1)

Projektová dokumentácia

Tím: Ivan Yachmenov (I-API-AI)
Viacheslav Kolesnikov (I-API-ISS)
Hlib Dorosh (I-API-ISS)
Ihor Shpetun (I-API-AI)
Dmytro Loiko (I-API-ISS)

Vedúci projektu: Lukáš Šurab

Spolupráca: Alison Slovakia s.r.o.

Bratislava **akademický rok 2026/2027**

Obsah

Úvod **3**

1 Oficiálne zadanie **4**

2 Tím a ponuka **6**

3 Ciele riešenia **7**

3.1 Hlavný cieľ 7

3.2 Čiastkové ciele 7

4 Analýza problematiky **8**

5 Návrh a architektúra systému **9**

5.1 Princípy návrhu 9

5.2 Komponenty systému 11

5.3 Orchestrátor a agenti 11

5.4 Informačný model profilu 11

5.5 Nasadenie 12

5.6 Priebeh auditu 13

Záver **15**

Literatúra **16**

Zoznam značiek a skratiek

AI	Artificial Intelligence, umelá inteligencia
API	Application Programming Interface
CLI	Command-Line Interface, rozhranie príkazového riadka
FMTI	Foundation Model Transparency Index
GPU	Graphics Processing Unit, grafický procesor
JSON	JavaScript Object Notation
LLM	Large Language Model, veľký jazykový model
MITRE ATLAS	Adversarial Threat Landscape for Artificial-Intelligence Systems
OWASP	Open Worldwide Application Security Project
STU	Slovenská technická univerzita v Bratislave
TP	Tímový projekt
UML	Unified Modeling Language

Úvod

Pri posudzovaní bezpečnosti a governance AI systémov je potrebné pracovať s informáciami, ktoré sú rozdelené medzi viacero zdrojov: model cards, technickú dokumentáciu, informácie o trénovacích dátach, výsledky evaluácií a bezpečnostné deklarácie výrobcu. Tieto zdroje majú rôznu štruktúru, rôznu mieru úplnosti a často si navzájom nezodpovedajú [1, 2]. Ich manuálne spracovanie je preto časovo náročné a výsledné hodnotenie do veľkej miery závisí od skúseností hodnotiteľa.

Cieľom tímového projektu je navrhnúť a implementovať prototyp systému, ktorý dokáže informácie o AI modeli alebo AI systéme automatizovane zhromaždiť, prepojiť a vyhodnotiť, vytvoriť z nich bezpečnostný a governance profil a identifikovať riziká, nedostatky a chýbajúce informácie. Každé zistenie má byť spätne dohľadateľné k dôkazu, z ktorého vzniklo. Projekt sa rieši v spolupráci so spoločnosťou Alison Slovakia s.r.o.

Tento dokument je projektovou dokumentáciou tímového projektu a bude sa priebežne dopĺňať. Obsahuje oficiálne zadanie projektu, zloženie tímu a odkaz na ponuku, ciele riešenia, prvý návrh architektúry systému a zoznam použitej literatúry. Analýza problematiky a ďalšie kapitoly budú doplnené v priebehu riešenia.

1 Oficiálne zadanie

Názov: Inteligentný systém pre automatizované hodnotenie bezpečnosti a governance AI systémov

Cieľ práce: Tímový projekt v spolupráci so spoločnosťou Alison Slovakia s.r.o. Cieľom je navrhnúť a implementovať systém, ktorý dokáže automatizovane zhromažďovať a vyhodnocovať informácie o AI modeli alebo AI systéme, vytvárať jeho bezpečnostný a governance profil a identifikovať riziká, nedostatky a chýbajúce informácie na základe dostupných dôkazov.

Anotácia: Informácie potrebné na posúdenie AI systému sú často rozdelené medzi model cards, technickú dokumentáciu, informácie o použitých dátach, evaluačné výsledky, bezpečnostné deklarácie a ďalšie zdroje. Ich manuálne spracovanie je časovo náročné a výsledné hodnotenie môže výrazne závisieť od skúseností hodnotiteľa. Projekt sa zameria na vytvorenie inteligentného systému, ktorý bude tieto informácie automatizovane získavať, prepájať a využívať pri hodnotení bezpečnosti a governance AI riešení. Systém môže vytvárať štruktúrovaný profil AI modelu alebo systému, automaticky dopĺňať model card, identifikovať relevantné riziká, vytvárať threat model alebo vykonávať ďalšie formy bezpečnostného a governance hodnotenia. Ak pre rozhodnutie nebudú dostupné dostatočné informácie, systém bude schopný identifikovať chýbajúce informácie, generovať doplňujúce otázky alebo požiadavky na ďalšie zdroje. Zistenia budú mapované na vybrané bezpečnostné a governance požiadavky a spätne dohľadateľné k dôkazom, z ktorých vznikli. Výsledkom bude prototyp adaptívneho hodnotiaceho systému, ktorý dokáže postupne vytvárať a spresňovať bezpečnostný a governance profil AI riešenia.

Úlohy:

1. Navrhnúť jednotný model informácií o AI riešení zahŕňajúci vybrané oblasti: model card, účel a obmedzenia použitia, informácie o dátach, evaluačné výsledky, bezpečnostné vlastnosti, ďalšie relevantné charakteristiky hodnoteného riešenia.

2. Implementovať automatizovaný zber, extrakciu a prepájanie informácií z model cards, technickej dokumentácie a ďalších dostupných zdrojov.

3. Implementovať vybrané automatizované hodnotiace mechanizmy: tvorbu alebo dopĺňanie model card, threat modeling, identifikáciu bezpečnostných rizík, kontrolu splnenia definovaných požiadaviek.

4. Implementovať adaptívne hodnotenie schopné identifikovať chýbajúce informácie, generovať doplňujúce otázky a pracovať s mierou istoty jednotlivých zistení.

5. Vyhodnotiť systém na vybraných AI modeloch alebo systémoch z pohľadu správnosti a úplnosti získaných informácií, kvality vytvorených hodnotení, identifikovaných rizík a dohľadateľnosti zistení k zdrojovým dôkazom.

2 Tím a ponuka

Projekt rieši päťčlenný tím študentov inžinierskeho štúdia na Fakulte elektrotechniky a informatiky STU v Bratislave. Vedúcim projektu je Lukáš Šurab, projekt sa rieši v spolupráci so spoločnosťou Alison Slovakia s.r.o.

Tabuľka 2: Členovia tímu

Meno	**Študijný program**
Ivan Yachmenov	I-API-AI
Viacheslav Kolesnikov	I-API-ISS
Hlib Dorosh	I-API-ISS
Ihor Shpetun	I-API-AI
Dmytro Loiko	I-API-ISS

Informácie o projekte a priebežné výstupy sú zverejňované na webovej stránke projektu `https://ai-governance-tp.github.io`.

Tím na začiatku semestra odovzdal ponuku na projekt, ktorá obsahuje odbornosť jednotlivých členov tímu, motiváciu, rámcový návrh riešenia, predbežný plán projektu, predpokladané zdroje a rozvrh tímu.

3 Ciele riešenia

3.1 Hlavný cieľ

Hlavným cieľom projektu je vytvoriť prototyp adaptívneho systému, ktorý z dostupných podkladov o AI modeli alebo AI systéme automatizovane vytvorí jeho bezpečnostný a governance profil, identifikuje riziká, nedostatky a chýbajúce informácie a každé zistenie prepojí s dôkazom, z ktorého vzniklo.

3.2 Čiastkové ciele

Čiastkové ciele zodpovedajú piatim úlohám oficiálneho zadania (kapitola 1):

1. **Jednotný informačný model.** Navrhnúť štruktúru, ktorá jednotne opisuje AI riešenie v oblastiach model card, účel a obmedzenia použitia, informácie o dátach, evaluačné výsledky, bezpečnostné vlastnosti a ďalšie relevantné charakteristiky.

2. **Zber a extrakcia informácií.** Implementovať automatizované získavanie informácií z model cards, technickej dokumentácie a ďalších zdrojov, ich extrakciu do informačného modelu a vzájomné prepojenie.

3. **Hodnotiace mechanizmy.** Implementovať vybrané automatizované hodnotenia: tvorbu alebo dopĺňanie model card, threat modeling, identifikáciu bezpečnostných rizík a kontrolu splnenia definovaných požiadaviek.

4. **Adaptívne hodnotenie.** Umožniť systému rozpoznať chýbajúce informácie, generovať doplňujúce otázky a ku každému zisteniu uvádzať mieru istoty.

5. **Vyhodnotenie systému.** Overiť systém na vybraných AI modeloch alebo systémoch z hľadiska správnosti a úplnosti získaných informácií, kvality hodnotení, identifikovaných rizík a dohľadateľnosti zistení k zdrojovým dôkazom.

4 Analýza problematiky

Kapitola bude doplnená v priebehu riešenia projektu.

5 Návrh a architektúra systému

Kapitola obsahuje prvý návrh architektúry. Jednotlivé časti budú spresnené podľa výsledkov experimentov.

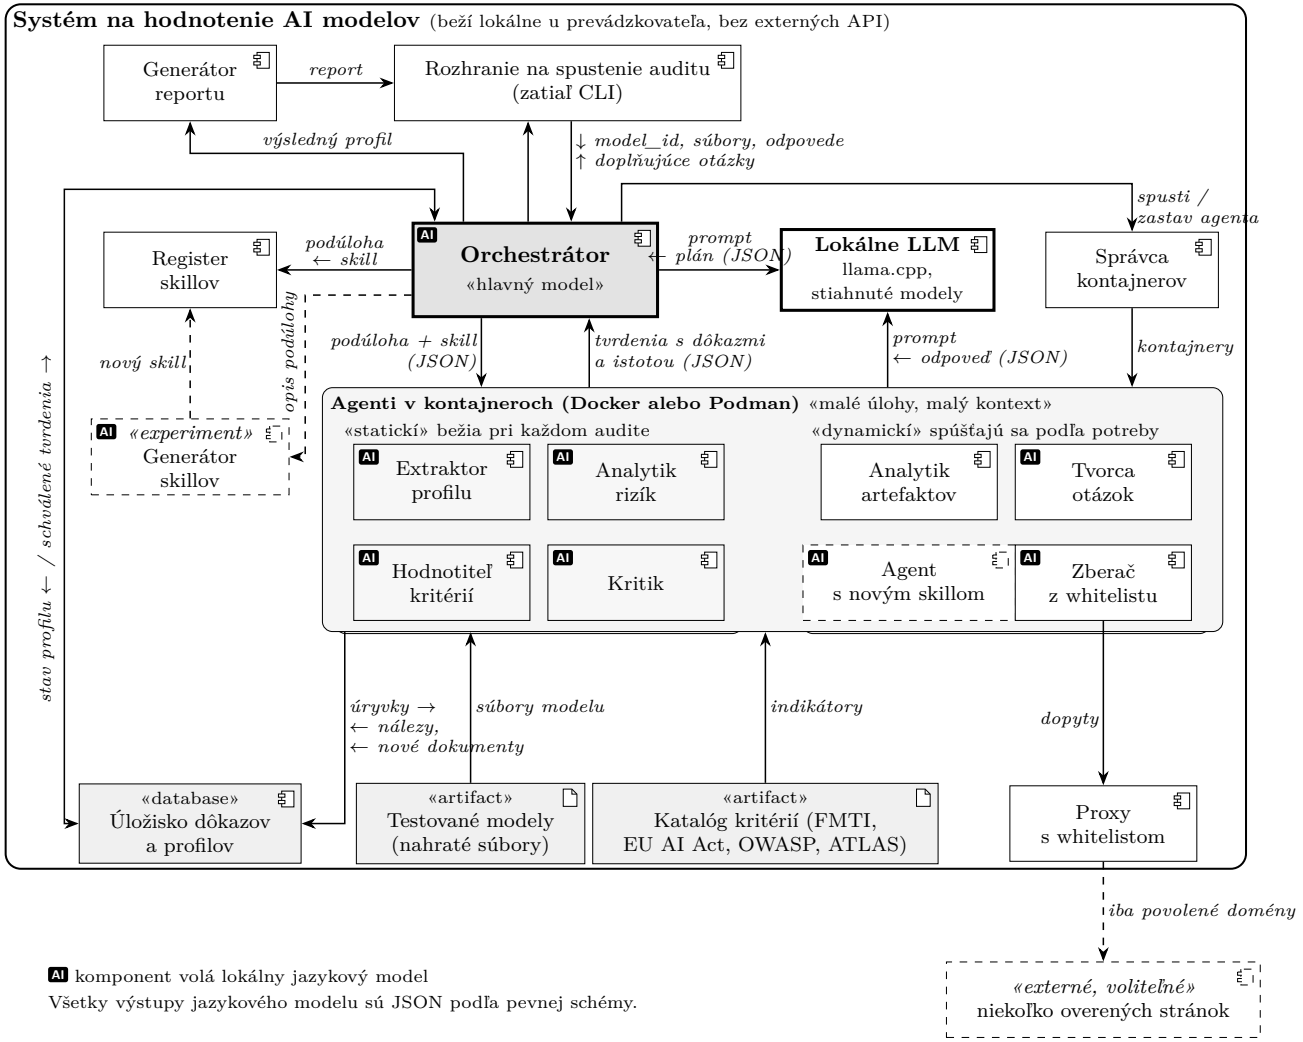
Jadrom systému je **orchestrátor**, komponent, ktorý na plánovanie využíva hlavný jazykový model. Audit AI modelu rozloží na menšie podúlohy a prideľuje ich **agentom**; agenti na svoje úlohy využívajú menšie jazykové modely s malým kontextom. *Statickí* agenti sú potrební pri každom audite a bežia stále, *dynamickí* sa spúšťajú a zastavujú podľa potreby. Systém nie je viazaný na konkrétne prostredie: beží na ľubovoľnom počítači s GPU a kontajnerovým runtime, napríklad na serveri školy alebo firmy.

5.1 Princípy návrhu

- **Všetko lokálne.** Systém nepoužíva žiadne externé API. Jazykové modely sú stiahnuté na hostiteľskom počítači a bežia v `llama-server` z projektu llama.cpp [3]. Testovaný model sa nahrá ako súbory.
- **Internet iba výnimočne.** Prístup von je vypnutý; ak je potrebný, ide cez proxy na niekoľko overených stránok (whitelist).
- **Žiadne zistenie bez dôkazu.** Každé tvrdenie v profile odkazuje na konkrétny úryvok zdroja, inak sa údaj označí ako chýbajúci.
- **Malé úlohy namiesto jednej veľkej.** Agent rieši úzku podúlohu s malým kontextom, čo znižuje riziko halucinácií.
- **Kontrola kritikom.** Každé tvrdenie, ktoré vytvorí jazykový model, overí kritik (vzor actor-critic a self-refine [4]).

Skill. Skill je opis jednej schopnosti agenta, ktorý tvoria tri časti: inštrukcia pre jazykový model (prompt), zoznam povolených nástrojov a JSON schéma výstupu. Skilly sú uložené v registri skillov; orchestrátor ku každej podúlohe vyberie vhodný skill a odovzdá ho agentovi spolu s podúlohou. V experimentálnom variante môže generátor skillov vytvoriť nový skill, ak žiadny z existujúcich nevyhovuje; systém sa porovná s touto možnosťou aj bez nej.

Prečo kontajnery. Samostatný kontajner je nutný najmä pre analytika artefaktov, ktorý číta súbory testovaného modelu: súbory vo formáte pickle môžu pri načítaní spustiť ľubovoľný kód [5], preto sa spracúvajú izolovane a bez prístupu na internet (komunikuje iba s databázou vo vnútornej sieti kontajnerov). Zberač ako jediný potrebuje internet, preto beží oddelene za proxy. Agenti, ktorí iba volajú jazykový model, sú v kontajneroch



Obr. 1: UML diagram komponentov systému (šípky znázorňujú tok dát)

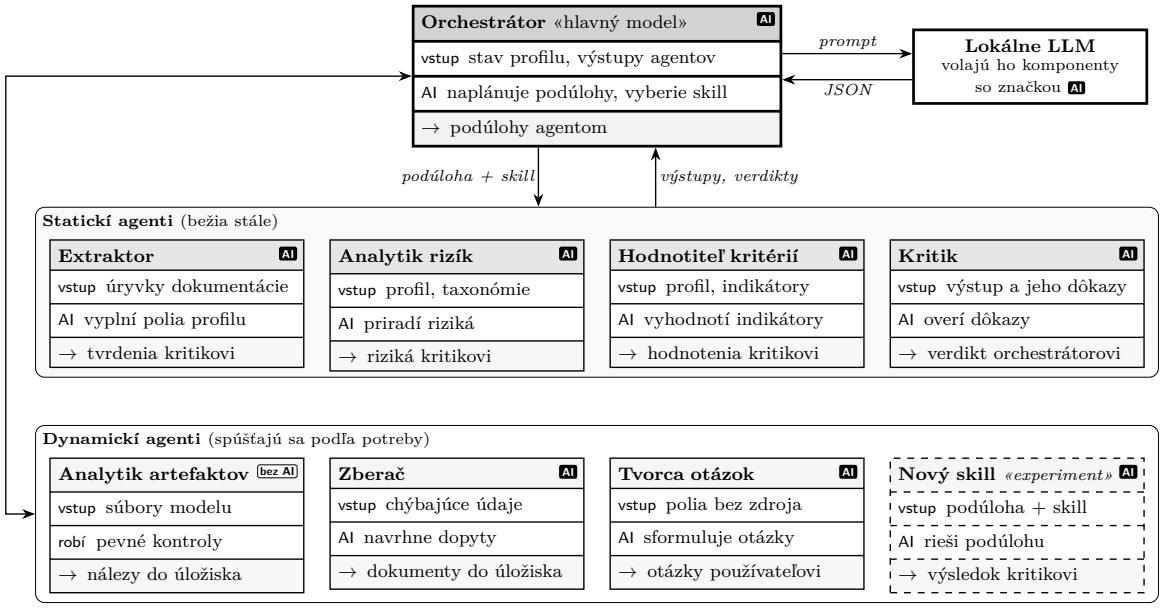
kvôli jednotnému nasadeniu a nezávislému spúšťaniu; ak sa to ukáže ako zbytočná réžia, môžu bežať ako procesy v kontajneri orchestrátora.

5.2 Komponenty systému

Obrázok 1 zachytáva štruktúru systému ako UML diagram komponentov. Plné šípky s popisom nie sú závislosti v zmysle UML, ale ukazujú *tok dát* medzi komponentmi. Značka AI označuje komponenty, ktoré volajú jazykový model. Úložisko dôkazov je databáza, testované modely a katalóg kritérií sú dáta (artefakty). Audit sa zatiaľ spúšťa z príkazového riadka (CLI). Prerušovanou čiarou je vyznačená experimentálna časť s generátorom skillov.

5.3 Orchestrátor a agenti

Obrázok 2 je prehľadový diagram (nie UML), ktorý pre orchestrátor a každého agenta uvádza vstup, úlohu jazykového modelu a výstup s jeho cieľom. Výstupy agentov s jazykovým modelom idú ku kritikovi. Výstupy bez jazykového modelu, teda nálezy deterministických kontrol analytika artefaktov a dokumenty stiahnuté zberačom, sa ukladajú priamo do úložiska; otázky tvorcu otázok idú cez orchestrátor používateľovi.

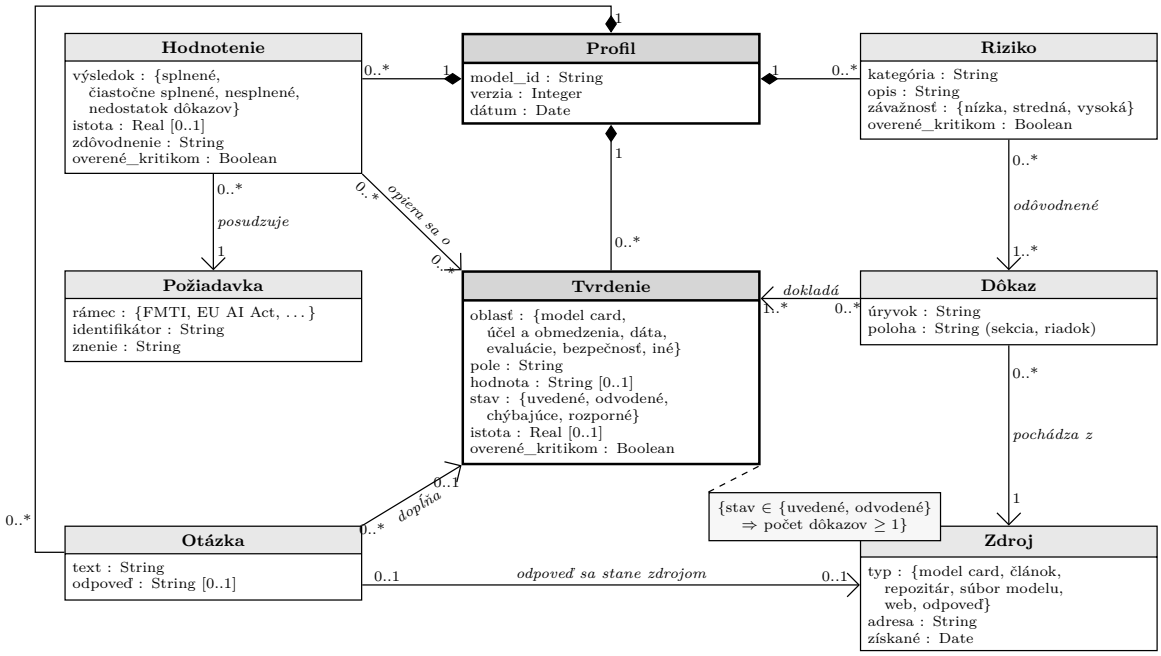


Obr. 2: Prehľadový diagram orchestrátora a agentov

5.4 Informačný model profilu

Obrázok 3 zachytáva jednotný informačný model profilu ako UML diagram tried. Základnou jednotkou nie je hodnota, ale *tvrdenie*: pole profilu s hodnotou, stavom

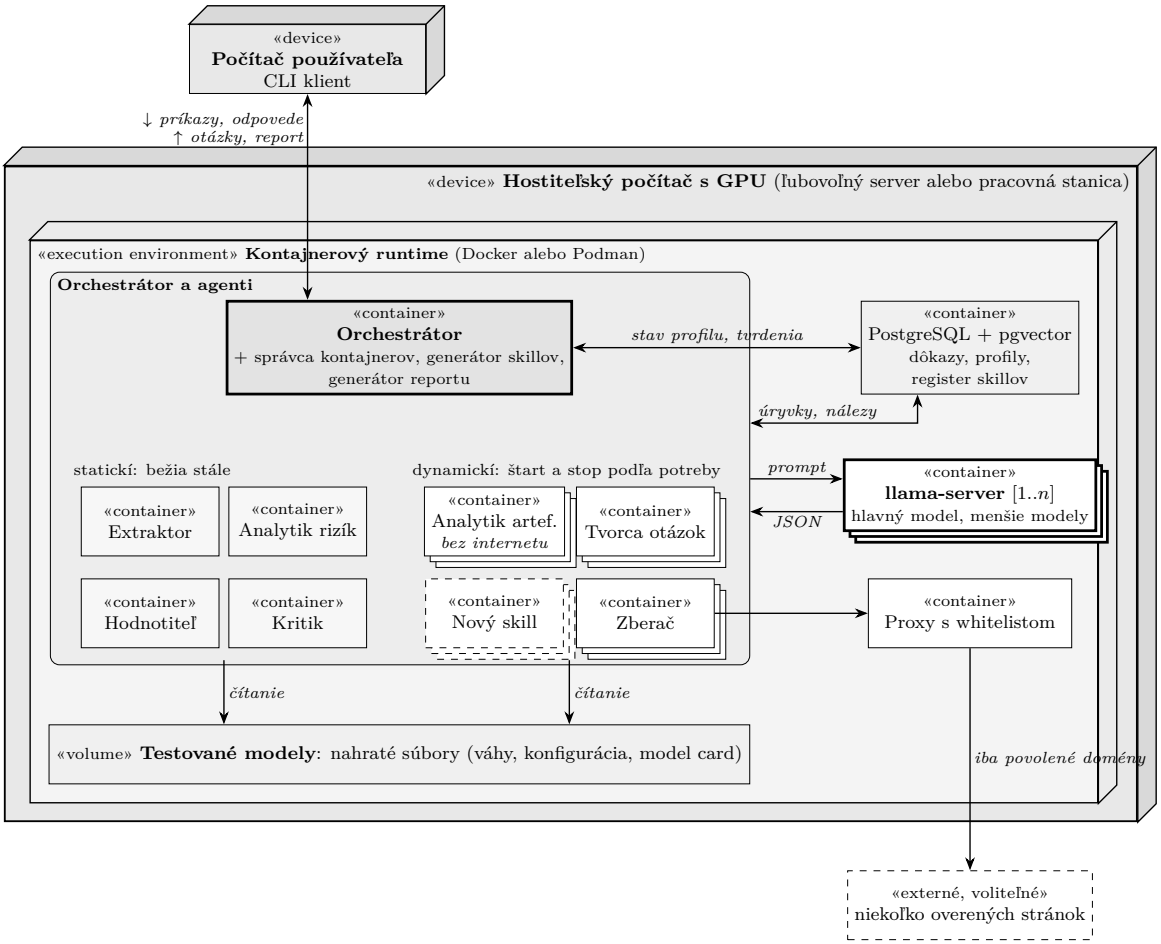
(uvedené, odvodené, chýbajúce, rozporné) a mierou istoty. Atribút *oblasť* priraďuje tvrdenie k jednej z oblastí profilu podľa zadania (model card, účel a obmedzenia, dáta, evaluácie, bezpečnosť). Tvrdenie so stavom uvedené alebo odvodené musí mať aspoň jeden dôkaz, teda úryvok s polohou v konkrétnom zdroji; toto obmedzenie je na diagrame zapísané pri triede Tvrdenie. Jeden úryvok môže dokladať viac tvrdení. Riziká, hodnotenia požiadaviek a doplňujúce otázky sú súčasťou profilu; odpoveď používateľa na otázku sa uloží ako nový zdroj. Zoznam polí profilu (atribúty extrahované z model cards) bude doplnený.



Obr. 3: UML diagram tried informačného modelu profilu

5.5 Nasadenie

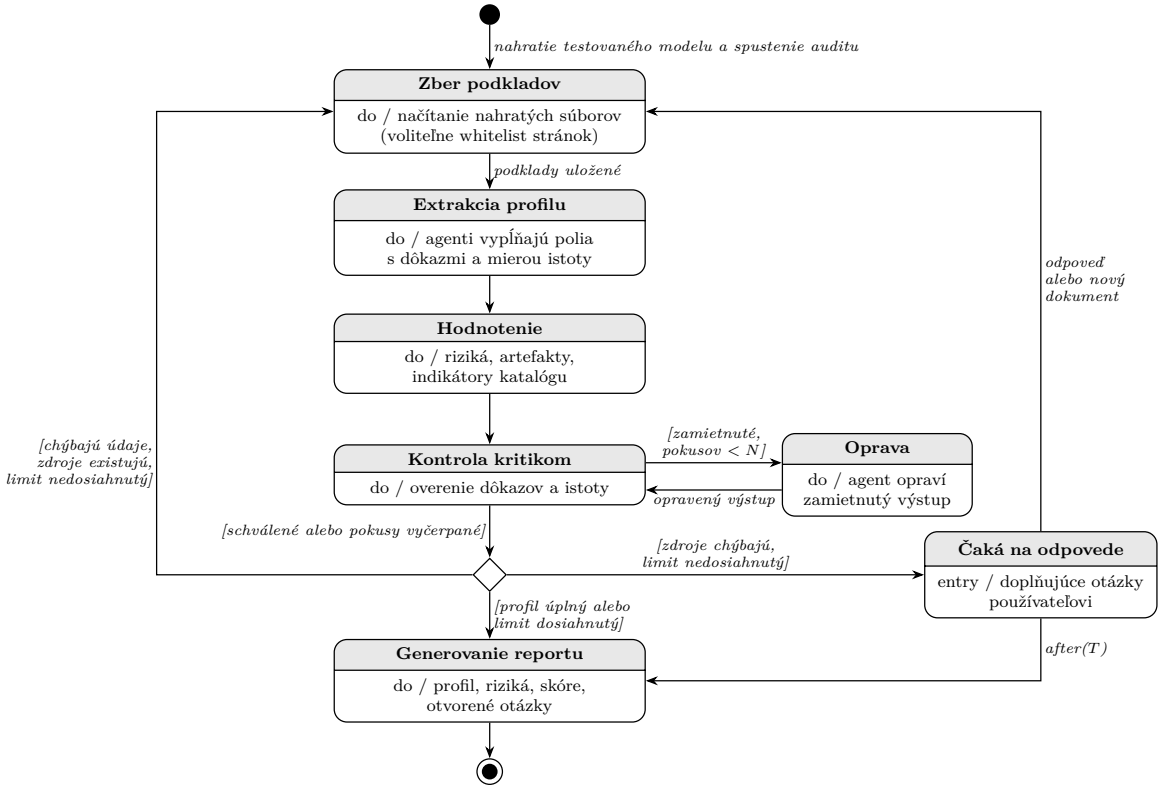
Obrázok 4 ukazuje rozmiestnenie komponentov na hostiteľskom počítači. Každá časť systému je samostatný kontajner (Docker alebo Podman). Používateľ ovláda systém cez CLI, lokálne alebo vzdialene; jazykové modely, databáza aj nahraté testované modely sú dostupné iba vnútri hostiteľa. Jazykové modely obsluhuje jedna alebo viac inštancií `llama-server`, keďže jedna inštancia obsluhuje jeden model (hlavný model orchestrátora a menšie modely agentov). Register skillov je uložený v databáze, generátor skillov a generátor reportu bežia v kontajneri orchestrátora. Analytik artefaktov nemá prístup na internet; s databázou komunikuje iba cez vnútornú sieť kontajnerov.



Obr. 4: UML diagram nasadenia

5.6 Priebeh auditu

Obrázok 5 opisuje priebeh auditu jedného modelu ako UML stavový diagram. Každé tvrdenie AI agenta prechádza kontrolou kritika; zamietnutý výstup opraví ten agent, ktorý ho vytvoril. Audit má limity: počet opráv jedného výstupu, počet iterácií a čas čakania na odpoveď používateľa. Po ich vyčerpaní sa audit ukončí reportom, v ktorom zostanú neoverené tvrdenia a nezodpovedané otázky označené ako otvorené.



Obr. 5: UML stavový diagram priebehu auditu

Záver

Kapitola bude doplnená v priebehu riešenia projektu.

Literatúra

1. MITCHELL, M. et al. Model Cards for Model Reporting. In: *FAT* '19: Conference on Fairness, Accountability, and Transparency* [online]. Atlanta, 2019 [cit. 2026-10-20]. Dostupné z arXiv: 1810.03993.
2. LIANG, W. et al. What's documented in AI? Systematic Analysis of 32K AI Model Cards. *Nature Machine Intelligence* [online]. 2024 [cit. 2026-10-20]. Dostupné z arXiv: 2402.05160.
3. GGML-ORG. *llama.cpp: LLM inference in C/C++* [online]. [cit. 2026-10-21]. Dostupné z: https://github.com/ggml-org/llama.cpp.
4. MADAAN, A. et al. *Self-Refine: Iterative Refinement with Self-Feedback* [online]. 2023-03-30. [cit. 2026-10-20]. Dostupné z arXiv: 2303.17651.
5. HUGGING FACE. *Pickle Scanning* [online]. [cit. 2026-10-21]. Dostupné z: https://huggingface.co/docs/hub/security-pickle.
6. TOMA, T. R.; GREWAL, B.; BEZEMER, C.-P. *Automatic Model Card Generation Using an LLM* [online]. 2026-08-25. [cit. 2026-10-20]. Dostupné z arXiv: 2608.24807.
7. LIU, J.; LI, W.; JIN, Z.; DIAB, M. Automatic Generation of Model and Data Cards: A Step Towards Responsible AI. In: *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL 2024)* [online]. 2024 [cit. 2026-10-20]. Dostupné z arXiv: 2405.06258.
8. RAO, P. S. B.; ŠĆEPANOVIĆ, S.; ZHOU, K.; BOGUCKA, E. P.; QUERCIA, D. *RiskRAG: A Data-Driven Solution for Improved AI Model Risk Reporting* [online]. 2025-04-11. [cit. 2026-10-20]. Dostupné z arXiv: 2504.08952.
9. WAN, A. et al. *The 2025 Foundation Model Transparency Index* [online]. Stanford CRFM, 2025-12-11. [cit. 2026-10-20]. Dostupné z arXiv: 2512.10169.
10. STANFORD CRFM. *Foundation Model Transparency Index: indicators (fmti-indicators.csv)* [online]. [cit. 2026-10-22]. Dostupné z: https://github.com/stanford-crfm/fmti.
11. MASOUDIFARD, A.; SOROND, M. M.; MADADI, M.; SABOKROU, M.; HABIBI, E. *Leveraging Graph-RAG and Prompt Engineering to Enhance LLM-Based Automated Requirement Traceability and Compliance Checks* [online]. 2024-12-11. [cit. 2026-10-20]. Dostupné z arXiv: 2412.08593.

12. AGARWAL, B.; JOMRAJ, H. S.; KAPLUNOV, S.; KROLICK, J.; ROJKOVA, V. *RAGulating Compliance: A Multi-Agent Knowledge Graph for Regulatory QA* [online]. 2025-08-13. [cit. 2026-10-20]. Dostupné z arXiv: 2508.09893.

13. ROMAN, M.; RAFFERTY, K.; DEVEREUX, B. *CTRAG: An In-Context Retrieval-based Framework for Automated Compliance Checking using LLMs* [online]. 2026-08-03. [cit. 2026-10-20]. Dostupné z arXiv: 2608.02472.

14. MAURI, L.; DAMIANI, E. Modeling Threats to AI-ML Systems Using STRIDE. *Sensors* [online]. 2022, **22**(17) [cit. 2026-10-20]. Dostupné z: https://pmc.ncbi.nlm.nih.gov/articles/PMC9459912/.

15. WEIDINGER, L. et al. Taxonomy of Risks posed by Language Models. In: *2022 ACM Conference on Fairness, Accountability, and Transparency (FAccT '22)* [online]. 2022 [cit. 2026-10-20]. Dostupné z DOI: 10.1145/3531146.3533088.

16. EURÓPSKY PARLAMENT A RADA EÚ. *Nariadenie (EÚ) 2024/1689, ktorým sa stanovujú harmonizované pravidlá v oblasti umelej inteligencie (akt o umelej inteligencii)* [online]. 2024. [cit. 2026-10-20]. Dostupné z: https://ai-act-service-desk.ec.europa.eu/en/ai-act/article-11.

17. NATIONAL INSTITUTE OF STANDARDS AND TECHNOLOGY. *Artificial Intelligence Risk Management Framework (AI RMF 1.0)* [online]. Gaithersburg, 2023 [cit. 2026-10-20]. NIST AI 100-1. NIST. Dostupné z DOI: 10.6028/NIST.AI.100-1.

18. NATIONAL INSTITUTE OF STANDARDS AND TECHNOLOGY. *AI RMF Playbook* [online]. [cit. 2026-10-20]. Dostupné z: https://airc.nist.gov/airmf-resources/playbook.

19. ISO/IEC. *ISO/IEC 42001:2023 Information technology – Artificial intelligence – Management system* [online]. 2023. [cit. 2026-10-20]. Dostupné z: https://www.iso.org/standard/81230.html.

20. OWASP FOUNDATION. *OWASP Top 10 for LLM Applications 2025* [online]. 2025. [cit. 2026-10-20]. Dostupné z: https://genai.owasp.org/llm-top-10/.

21. MITRE. *MITRE ATLAS: Adversarial Threat Landscape for Artificial-Intelligence Systems* [online]. 2025. [cit. 2026-10-20]. Dostupné z: https://atlas.mitre.org/.

22. MICROSOFT. *Threat Modeling AI/ML Systems and Dependencies* [online]. 2022. [cit. 2026-10-20]. Dostupné z: https://learn.microsoft.com/en-us/security/engineering/threat-modeling-aiml/.

23. HUGGING FACE. *huggingface_hub: Repository Cards* [online]. [cit. 2026-10-20]. Dostupné z: https://huggingface.co/docs/huggingface_hub/package_reference/cards.

24. HUGGING FACE. *Model Cards* [online]. [cit. 2026-10-20]. Dostupné z: https://huggingface.co/docs/hub/model-cards.

25. OLLAMA. *Ollama: Documentation* [online]. [cit. 2026-10-20]. Dostupné z: https://github.com/ollama/ollama.

26. VLLM. *vLLM Documentation* [online]. [cit. 2026-10-20]. Dostupné z: https://docs.vllm.ai/.

27. INSTRUCTOR. *Instructor: Structured outputs for LLMs* [online]. [cit. 2026-10-20]. Dostupné z: https://python.useinstructor.com/.

28. DOTTXT. *Outlines: Structured text generation* [online]. [cit. 2026-10-20]. Dostupné z: https://github.com/dottxt-ai/outlines.

29. PGVECTOR. *pgvector: Open-source vector similarity search for Postgres* [online]. [cit. 2026-10-20]. Dostupné z: https://github.com/pgvector/pgvector.

30. NVIDIA. *garak: LLM vulnerability scanner* [online]. [cit. 2026-10-20]. Dostupné z: https://github.com/NVIDIA/garak.

31. GISKARD. *Giskard: Open-Source Evaluation & Testing library for LLM Agents* [online]. [cit. 2026-10-20]. Dostupné z: https://github.com/Giskard-AI/giskard-oss.

32. HOLISTIC AI. *holisticai: open-source library* [online]. [cit. 2026-10-20]. Dostupné z: https://github.com/holistic-ai/holisticai.

33. IBM. *Docling: document parsing* [online]. [cit. 2026-10-20]. Dostupné z: https://github.com/docling-project/docling.

34. HUGGING FACE. *safetensors: Simple, safe way to store and distribute tensors* [online]. [cit. 2026-10-21]. Dostupné z: https://github.com/huggingface/safetensors.

35. PROTECT AI. *ModelScan: Protection against Model Serialization Attacks* [online]. [cit. 2026-10-21]. Dostupné z: https://github.com/protectai/modelscan.

36. OWASP CYCLONEDX. *Machine Learning Bill of Materials (ML-BOM)* [online]. [cit. 2026-10-21]. Dostupné z: https://cyclonedx.org/capabilities/mlbom/.

37. MICROSOFT. *PyRIT: Python Risk Identification Tool for generative AI* [online]. [cit. 2026-10-21]. Dostupné z: https://github.com/microsoft/PyRIT.

38. UK AI SECURITY INSTITUTE. *Inspect: An open-source framework for large language model evaluations* [online]. [cit. 2026-10-21]. Dostupné z: https://inspect.aisi.org.uk/.

39. CREDO AI. *Credo AI: Product overview* [online]. [cit. 2026-10-20]. Dostupné z: https://www.credo.ai/product.

40. HOLISTIC AI. *AI Governance Platform* [online]. [cit. 2026-10-20]. Dostupné z: https://www.holisticai.com/ai-governance-platform.

41. IBM. *watsonx.governance* [online]. [cit. 2026-10-20]. Dostupné z: https://www.ibm.com/products/watsonx-governance.

42. IBM TECHNOLOGY. *What is Retrieval-Augmented Generation (RAG)?* [YouTube]. [cit. 2026-10-20]. Dostupné z: https://www.youtube.com/watch?v=T-D1OfcDW1M.

43. CONFIDENT AI. *OWASP Top 10 2025 for LLM Applications: Risks and Mitigation Techniques* [online]. [cit. 2026-10-20]. Dostupné z: https://www.confident-ai.com/blog/owasp-top-10-2025-for-llm-applications-risks-and-mitigation-techniques.

44. OWASP GENAI SECURITY PROJECT. *AIBOM Generator* [online]. [cit. 2026-10-21]. Dostupné z: https://github.com/GenAI-Security-Project/aibom-generator.

45. LIU, J. *AutomatedModelCardGeneration: kód a dátová množina CardBench* [online]. [cit. 2026-10-21]. Dostupné z: https://github.com/jiarui-liu/AutomatedModelCardGeneration.

46. ZHANG, H. et al. AdaQE-CG: Adaptive Query Expansion for Web-Scale Generative AI Model and Data Card Generation. In: *Proceedings of the ACM Web Conference (WWW 2026)* [online]. 2026 [cit. 2026-10-21]. Dostupné z arXiv: 2604.09617.

47. GULDIMANN, P. et al. *COMPL-AI Framework: A Technical Interpretation and LLM Benchmarking Suite for the EU Artificial Intelligence Act* [online]. 2024. [cit. 2026-10-21]. Dostupné z arXiv: 2410.07959.

48. WHITE, M.; HADDAD, I.; OSBORNE, C. et al. *The Model Openness Framework: Promoting Completeness and Openness for Reproducibility, Transparency, and Usability in AI* [online]. 2024. [cit. 2026-10-21]. Dostupné z arXiv: 2403.13784.

49. MIT FUTURETECH. *The AI Risk Repository* [online]. [cit. 2026-10-21]. Dostupné z: https://airisk.mit.edu/.

50. HADFIELD, J. et al. *How we built our multi-agent research system* [online]. Anthropic, 2025-06-13. [cit. 2026-10-21]. Dostupné z: https://www.anthropic.com/engineering/multi-agent-research-system.

51. FOURNEY, A. et al. *Magentic-One: A Generalist Multi-Agent System for Solving Complex Tasks* [online]. Microsoft Research, 2024. [cit. 2026-10-21]. Dostupné z arXiv: 2411.04468.

52. CHEN, G. et al. AutoAgents: A Framework for Automatic Agent Generation. In: *Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI 2024)* [online]. 2024 [cit. 2026-10-21]. Dostupné z arXiv: 2309.17288.

53. HUGGING FACE. *smolagents* [online]. [cit. 2026-10-21]. Dostupné z: https://github.com/huggingface/smolagents.

54. LANGCHAIN. *Open Deep Research* [online]. [cit. 2026-10-21]. Dostupné z: https://github.com/langchain-ai/open_deep_research.

55. YAO, S. et al. ReAct: Synergizing Reasoning and Acting in Language Models. In: *International Conference on Learning Representations (ICLR)* [online]. 2023 [cit. 2026-10-20]. Dostupné z arXiv: 2210.03629.

56. SHINN, N. et al. *Reflexion: Language Agents with Verbal Reinforcement Learning* [online]. 2023-03-20. [cit. 2026-10-20]. Dostupné z arXiv: 2303.11366.

57. YAN, S.-Q.; GU, J.-C.; ZHU, Y.; LING, Z.-H. *Corrective Retrieval Augmented Generation* [online]. 2024-01-29. [cit. 2026-10-20]. Dostupné z arXiv: 2401.15884.

58. HABIBZADEH, A.; FEYZI, F.; EBRAHIMI ATANI, R. Large Language Models for Security Operations Centers: A Comprehensive Survey. *Journal of Electrical and Computer Engineering* [online]. 2026, (3383674) [cit. 2026-10-20]. Dostupné z arXiv: 2509.10858.

59. LANGCHAIN. *LangSmith* [online]. [cit. 2026-10-20]. Dostupné z: https://smith.langchain.com/.