SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Inteligentný systém pre automatizované hodnotenie bezpečnosti a governance AI systémov

Tímový projekt (TP1)

Projektová dokumentácia

Tím: Ivan Yachmenov (I-API-AI)
Viacheslav Kolesnikov (I-API-ISS)
Hlib Dorosh (I-API-ISS)
Ihor Shpetun (I-API-AI)
Dmytro Loiko (I-API-ISS)

Vedúci projektu: Lukáš Šurab

Spolupráca: Alison Slovakia s.r.o.

Bratislava **akademický rok 2026/2027**

Obsah

Úvod **4**

1 Oficiálne zadanie **5**

2 Tím a ponuka **7**

3 Ciele riešenia **8**

3.1 Hlavný cieľ 8

3.2 Čiastkové ciele 8

4 Analýza problému **9**

5 Návrh riešenia (algoritmy a metódy) **10**

6 Dokumentácia k programom **11**

7 Výsledky a porovnanie s existujúcimi riešeniami **12**

Záver **13**

Literatúra **14**

Zoznam značiek a skratiek

AI	Artificial Intelligence, umelá inteligencia
AI Act	Nariadenie (EÚ) 2024/1689 o umelej inteligencii
AI RMF	Artificial Intelligence Risk Management Framework (NIST)
API	Application Programming Interface
CRAG	Corrective Retrieval Augmented Generation
CRFM	Center for Research on Foundation Models (Stanford)
EÚ	Európska únia
FEI	Fakulta elektrotechniky a informatiky
GPAI	General-Purpose AI, AI model na všeobecné účely
GPU	Graphics Processing Unit
HF	Hugging Face
ISO/IEC	International Organization for Standardization / International Electrotechnical Commission
JSON	JavaScript Object Notation
LLM	Large Language Model, veľký jazykový model
MITRE ATLAS	Adversarial Threat Landscape for Artificial-Intelligence Systems
ML	Machine Learning, strojové učenie
NIST	National Institute of Standards and Technology
OWASP	Open Worldwide Application Security Project
PDF	Portable Document Format
RAG	Retrieval-Augmented Generation
REST	Representational State Transfer
SOC	Security Operations Center
SSH	Secure Shell

STRIDE	Spoofing, Tampering, Repudiation, Information Disclosure, Denial of Service, Elevation of Privilege
STU	Slovenská technická univerzita v Bratislave
TP	Tímový projekt
UML	Unified Modeling Language

Úvod

Pri posudzovaní bezpečnosti a governance AI systémov je potrebné pracovať s informáciami, ktoré sú rozdelené medzi viacero zdrojov: model cards, technickú dokumentáciu, informácie o trénovacích dátach, výsledky evaluácií a bezpečnostné deklarácie výrobcu. Tieto zdroje majú rôznu štruktúru, rôznu mieru úplnosti a často si navzájom nezodpovedajú [1, 2]. Ich manuálne spracovanie je preto časovo náročné a výsledné hodnotenie do veľkej miery závisí od skúseností hodnotiteľa.

Cieľom tímového projektu je navrhnúť a implementovať prototyp systému, ktorý dokáže informácie o AI modeli alebo AI systéme automatizovane zhromaždiť, prepojiť a vyhodnotiť, vytvoriť z nich bezpečnostný a governance profil a identifikovať riziká, nedostatky a chýbajúce informácie. Každé zistenie má byť spätne dohľadateľné k dôkazu, z ktorého vzniklo. Projekt sa rieši v spolupráci so spoločnosťou Alison Slovakia s.r.o.

Tento dokument je projektovou dokumentáciou tímového projektu a bude sa priebežne dopĺňať. Obsahuje oficiálne zadanie projektu, zloženie tímu a odkaz na ponuku, ciele riešenia a zoznam použitej literatúry. Kapitoly venované analýze problému, návrhu riešenia, dokumentácii k programom a výsledkom budú doplnené v priebehu riešenia.

1 Oficiálne zadanie

Názov: Inteligentný systém pre automatizované hodnotenie bezpečnosti a governance AI systémov

Cieľ práce: Tímový projekt v spolupráci so spoločnosťou Alison Slovakia s.r.o. Cieľom je navrhnúť a implementovať systém, ktorý dokáže automatizovane zhromažďovať a vyhodnocovať informácie o AI modeli alebo AI systéme, vytvárať jeho bezpečnostný a governance profil a identifikovať riziká, nedostatky a chýbajúce informácie na základe dostupných dôkazov.

Anotácia: Informácie potrebné na posúdenie AI systému sú často rozdelené medzi model cards, technickú dokumentáciu, informácie o použitých dátach, evaluačné výsledky, bezpečnostné deklarácie a ďalšie zdroje. Ich manuálne spracovanie je časovo náročné a výsledné hodnotenie môže výrazne závisieť od skúseností hodnotiteľa. Projekt sa zameria na vytvorenie inteligentného systému, ktorý bude tieto informácie automatizovane získavať, prepájať a využívať pri hodnotení bezpečnosti a governance AI riešení. Systém môže vytvárať štruktúrovaný profil AI modelu alebo systému, automaticky dopĺňať model card, identifikovať relevantné riziká, vytvárať threat model alebo vykonávať ďalšie formy bezpečnostného a governance hodnotenia. Ak pre rozhodnutie nebudú dostupné dostatočné informácie, systém bude schopný identifikovať chýbajúce informácie, generovať doplňujúce otázky alebo požiadavky na ďalšie zdroje. Zistenia budú mapované na vybrané bezpečnostné a governance požiadavky a spätne dohľadateľné k dôkazom, z ktorých vznikli. Výsledkom bude prototyp adaptívneho hodnotiaceho systému, ktorý dokáže postupne vytvárať a spresňovať bezpečnostný a governance profil AI riešenia.

Úlohy:

1. Navrhnúť jednotný model informácií o AI riešení zahŕňajúci vybrané oblasti: model card, účel a obmedzenia použitia, informácie o dátach, evaluačné výsledky, bezpečnostné vlastnosti, ďalšie relevantné charakteristiky hodnoteného riešenia.

2. Implementovať automatizovaný zber, extrakciu a prepájanie informácií z model cards, technickej dokumentácie a ďalších dostupných zdrojov.

3. Implementovať vybrané automatizované hodnotiace mechanizmy: tvorbu alebo dopĺňanie model card, threat modeling, identifikáciu bezpečnostných rizík, kontrolu splnenia definovaných požiadaviek.

4. Implementovať adaptívne hodnotenie schopné identifikovať chýbajúce informácie, generovať doplňujúce otázky a pracovať s mierou istoty jednotlivých zistení.

5. Vyhodnotiť systém na vybraných AI modeloch alebo systémoch z pohľadu správnosti a úplnosti získaných informácií, kvality vytvorených hodnotení, identifikovaných rizík a dohľadateľnosti zistení k zdrojovým dôkazom.

2 Tím a ponuka

Projekt rieši päťčlenný tím študentov inžinierskeho štúdia na Fakulte elektrotechniky a informatiky STU v Bratislave. Vedúcim projektu je Lukáš Šurab, projekt sa rieši v spolupráci so spoločnosťou Alison Slovakia s.r.o.

Tabuľka 2: Členovia tímu

Meno	**Študijný program**
Ivan Yachmenov	I-API-AI
Viacheslav Kolesnikov	I-API-ISS
Hlib Dorosh	I-API-ISS
Ihor Shpetun	I-API-AI
Dmytro Loiko	I-API-ISS

Informácie o projekte a priebežné výstupy sú zverejňované na webovej stránke projektu `https://ai-governance-tp.github.io`.

Tím na začiatku semestra odovzdal ponuku na projekt, ktorá obsahuje odbornosť jednotlivých členov tímu, motiváciu, rámcový návrh riešenia, predbežný plán projektu, predpokladané zdroje a rozvrh tímu.

3 Ciele riešenia

3.1 Hlavný cieľ

Hlavným cieľom projektu je vytvoriť prototyp adaptívneho systému, ktorý z dostupných podkladov o AI modeli alebo AI systéme automatizovane vytvorí jeho bezpečnostný a governance profil, identifikuje riziká, nedostatky a chýbajúce informácie a každé zistenie prepojí s dôkazom, z ktorého vzniklo.

3.2 Čiastkové ciele

Čiastkové ciele zodpovedajú piatim úlohám oficiálneho zadania (kapitola 1):

1. **Jednotný informačný model.** Navrhnúť štruktúru, ktorá jednotne opisuje AI riešenie v oblastiach model card, účel a obmedzenia použitia, informácie o dátach, evaluačné výsledky, bezpečnostné vlastnosti a ďalšie relevantné charakteristiky.

2. **Zber a extrakcia informácií.** Implementovať automatizované získavanie informácií z model cards, technickej dokumentácie a ďalších zdrojov, ich extrakciu do informačného modelu a vzájomné prepojenie.

3. **Hodnotiace mechanizmy.** Implementovať vybrané automatizované hodnotenia: tvorbu alebo dopĺňanie model card, threat modeling, identifikáciu bezpečnostných rizík a kontrolu splnenia definovaných požiadaviek.

4. **Adaptívne hodnotenie.** Umožniť systému rozpoznať chýbajúce informácie, generovať doplňujúce otázky a ku každému zisteniu uvádzať mieru istoty.

5. **Vyhodnotenie systému.** Overiť systém na vybraných AI modeloch alebo systémoch z hľadiska správnosti a úplnosti získaných informácií, kvality hodnotení, identifikovaných rizík a dohľadateľnosti zistení k zdrojovým dôkazom.

4 Analýza problému

Kapitola bude doplnená v priebehu riešenia projektu.

5 Návrh riešenia (algoritmy a metódy)

Kapitola bude doplnená v priebehu riešenia projektu.

6 Dokumentácia k programom

Kapitola bude doplnená v priebehu riešenia projektu.

7 Výsledky a porovnanie s existujúcimi riešeniami

Kapitola bude doplnená v priebehu riešenia projektu.

Záver

Kapitola bude doplnená v priebehu riešenia projektu.

Literatúra

1. MITCHELL, M. et al. Model Cards for Model Reporting. In: *FAT* '19: Conference on Fairness, Accountability, and Transparency* [online]. Atlanta, 2019 [cit. 2026-10-20]. Dostupné z arXiv: 1810.03993.
2. LIANG, W. et al. What's documented in AI? Systematic Analysis of 32K AI Model Cards. *Nature Machine Intelligence* [online]. 2024 [cit. 2026-10-20]. Dostupné z arXiv: 2402.05160.
3. TOMA, T. R.; GREWAL, B.; BEZEMER, C.-P. *Automatic Model Card Generation Using an LLM* [online]. 2026-08-25. [cit. 2026-10-20]. Dostupné z arXiv: 2608.24807.
4. LIU, J.; LI, W.; JIN, Z.; DIAB, M. Automatic Generation of Model and Data Cards: A Step Towards Responsible AI. In: *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL 2024)* [online]. 2024 [cit. 2026-10-20]. Dostupné z arXiv: 2405.06258.
5. RAO, P. S. B.; ŠĆEPANOVIĆ, S.; ZHOU, K.; BOGUCKA, E. P.; QUERCIA, D. *RiskRAG: A Data-Driven Solution for Improved AI Model Risk Reporting* [online]. 2025-04-11. [cit. 2026-10-20]. Dostupné z arXiv: 2504.08952.
6. WAN, A. et al. *The 2025 Foundation Model Transparency Index* [online]. Stanford CRFM, 2025-12-11. [cit. 2026-10-20]. Dostupné z arXiv: 2512.10169.
7. MASOUDIFARD, A.; SOROND, M. M.; MADADI, M.; SABOKROU, M.; HABIBI, E. *Leveraging Graph-RAG and Prompt Engineering to Enhance LLM-Based Automated Requirement Traceability and Compliance Checks* [online]. 2024-12-11. [cit. 2026-10-20]. Dostupné z arXiv: 2412.08593.
8. AGARWAL, B.; JOMRAJ, H. S.; KAPLUNOV, S.; KROLICK, J.; ROJKOVA, V. *RAGulating Compliance: A Multi-Agent Knowledge Graph for Regulatory QA* [online]. 2025-08-13. [cit. 2026-10-20]. Dostupné z arXiv: 2508.09893.
9. ROMAN, M.; RAFFERTY, K.; DEVEREUX, B. *CTRAG: An In-Context Retrieval-based Framework for Automated Compliance Checking using LLMs* [online]. 2026-08-03. [cit. 2026-10-20]. Dostupné z arXiv: 2608.02472.
10. MAURI, L.; DAMIANI, E. Modeling Threats to AI-ML Systems Using STRIDE. *Sensors* [online]. 2022, **22**(17) [cit. 2026-10-20]. Dostupné z: https://pmc.ncbi.nlm.nih.gov/articles/PMC9459912/.

11. WEIDINGER, L. et al. Taxonomy of Risks posed by Language Models. In: *2022 ACM Conference on Fairness, Accountability, and Transparency (FAccT '22)* [online]. 2022 [cit. 2026-10-20]. Dostupné z DOI: 10.1145/3531146.3533088.

12. EURÓPSKY PARLAMENT A RADA EÚ. *Nariadenie (EÚ) 2024/1689, ktorým sa stanovujú harmonizované pravidlá v oblasti umelej inteligencie (akt o umelej inteligencii)* [online]. 2024. [cit. 2026-10-20]. Dostupné z: https://ai-act-service-desk.ec.europa.eu/en/ai-act/article-11.

13. NATIONAL INSTITUTE OF STANDARDS AND TECHNOLOGY. *Artificial Intelligence Risk Management Framework (AI RMF 1.0)* [online]. Gaithersburg, 2023 [cit. 2026-10-20]. NIST AI 100-1. NIST. Dostupné z DOI: 10.6028/NIST.AI.100-1.

14. NATIONAL INSTITUTE OF STANDARDS AND TECHNOLOGY. *AI RMF Playbook* [online]. [cit. 2026-10-20]. Dostupné z: https://airc.nist.gov/airmf-resources/playbook.

15. ISO/IEC. *ISO/IEC 42001:2023 Information technology – Artificial intelligence – Management system* [online]. 2023. [cit. 2026-10-20]. Dostupné z: https://www.iso.org/standard/81230.html.

16. OWASP FOUNDATION. *OWASP Top 10 for LLM Applications 2025* [online]. 2025. [cit. 2026-10-20]. Dostupné z: https://genai.owasp.org/llm-top-10/.

17. MITRE. *MITRE ATLAS: Adversarial Threat Landscape for Artificial-Intelligence Systems* [online]. 2025. [cit. 2026-10-20]. Dostupné z: https://atlas.mitre.org/.

18. MICROSOFT. *Threat Modeling AI/ML Systems and Dependencies* [online]. 2022. [cit. 2026-10-20]. Dostupné z: https://learn.microsoft.com/en-us/security/engineering/threat-modeling-aiml/.

19. HUGGING FACE. *huggingface_hub: Repository Cards* [online]. [cit. 2026-10-20]. Dostupné z: https://huggingface.co/docs/huggingface_hub/package_reference/cards.

20. HUGGING FACE. *Model Cards* [online]. [cit. 2026-10-20]. Dostupné z: https://huggingface.co/docs/hub/model-cards.

21. OLLAMA. *Ollama: Documentation* [online]. [cit. 2026-10-20]. Dostupné z: https://github.com/ollama/ollama.

22. VLLM. *vLLM Documentation* [online]. [cit. 2026-10-20]. Dostupné z: https://docs.vllm.ai/.

23. INSTRUCTOR. *Instructor: Structured outputs for LLMs* [online]. [cit. 2026-10-20]. Dostupné z: https://python.useinstructor.com/.

24. DOTTXT. *Outlines: Structured text generation* [online]. [cit. 2026-10-20]. Dostupné z: https://github.com/dottxt-ai/outlines.

25. PGVECTOR. *pgvector: Open-source vector similarity search for Postgres* [online]. [cit. 2026-10-20]. Dostupné z: https://github.com/pgvector/pgvector.

26. NVIDIA. *garak: LLM vulnerability scanner* [online]. [cit. 2026-10-20]. Dostupné z: https://github.com/NVIDIA/garak.

27. GISKARD. *Giskard: Open-Source Evaluation & Testing library for LLM Agents* [online]. [cit. 2026-10-20]. Dostupné z: https://github.com/Giskard-AI/giskard-oss.

28. HOLISTIC AI. *holisticai: open-source library* [online]. [cit. 2026-10-20]. Dostupné z: https://github.com/holistic-ai/holisticai.

29. IBM. *Docling: document parsing* [online]. [cit. 2026-10-20]. Dostupné z: https://github.com/docling-project/docling.

30. CREDO AI. *Credo AI: Product overview* [online]. [cit. 2026-10-20]. Dostupné z: https://www.credo.ai/product.

31. HOLISTIC AI. *AI Governance Platform* [online]. [cit. 2026-10-20]. Dostupné z: https://www.holisticai.com/ai-governance-platform.

32. IBM. *watsonx.governance* [online]. [cit. 2026-10-20]. Dostupné z: https://www.ibm.com/products/watsonx-governance.

33. IBM TECHNOLOGY. *What is Retrieval-Augmented Generation (RAG)?* [YouTube]. [cit. 2026-10-20]. Dostupné z: https://www.youtube.com/watch?v=T-D1OfcDW1M.

34. CONFIDENT AI. *OWASP Top 10 2025 for LLM Applications: Risks and Mitigation Techniques* [online]. [cit. 2026-10-20]. Dostupné z: https://www.confident-ai.com/blog/owasp-top-10-2025-for-llm-applications-risks-and-mitigation-techniques.

35. YAO, S. et al. ReAct: Synergizing Reasoning and Acting in Language Models. In: *International Conference on Learning Representations (ICLR)* [online]. 2023 [cit. 2026-10-20]. Dostupné z arXiv: 2210.03629.

36. SHINN, N. et al. *Reflexion: Language Agents with Verbal Reinforcement Learning* [online]. 2023-03-20. [cit. 2026-10-20]. Dostupné z arXiv: 2303.11366.

37. YAN, S.-Q.; GU, J.-C.; ZHU, Y.; LING, Z.-H. *Corrective Retrieval Augmented Generation* [online]. 2024-01-29. [cit. 2026-10-20]. Dostupné z arXiv: 2401.15884.

38. MADAAN, A. et al. *Self-Refine: Iterative Refinement with Self-Feedback* [online]. 2023-03-30. [cit. 2026-10-20]. Dostupné z arXiv: 2303.17651.

39. HABIBZADEH, A.; FEYZI, F.; EBRAHIMI ATANI, R. Large Language Models for Security Operations Centers: A Comprehensive Survey. *Journal of Electrical and Computer Engineering* [online]. 2026, (3383674) [cit. 2026-10-20]. Dostupné z arXiv: 2509.10858.

40. LANGCHAIN. *LangSmith* [online]. [cit. 2026-10-20]. Dostupné z: https://smith.langchain.com/.